

Decisão Financeira - Trabalho 2



Alunos:

Bruno Jambeiro Mesquita RA: 260382

Lucas Rodrigues de Mendonça RA: 236800

Fernando Rodrigues da Silva RA: 247409

Thiago Augusto de Tulio Nascimento RA: 252937

Victor Itiro Ogitsu RA: 244075

Campinas

Abril 2026

Os arquivos podem ser encontrados no [repositório do projeto](#).

Abstract

Este relatório descreve o desenvolvimento de um agente inteligente modelado via Processo de Decisão de Markov (MDP) para tomada de decisão em um ambiente financeiro simulado. Foram implementadas e comparadas estratégias de planejamento através de Programação Dinâmica (Value Iteration) e de aprendizado livre de modelo via Q-learning. Os resultados demonstram a capacidade do agente em maximizar o lucro em diferentes representações de estados, incluindo tendências simples e médias móveis.

1 Modelagem do Problema

O problema de decisão financeira foi formalizado como um MDP (S, A, T, R) , onde o agente deve otimizar o retorno de seus investimentos ao longo do tempo.

- **Espaço de Estados (S):** Foram propostas três formas de discretização do mercado para avaliação: modelo simples de 1 dia, janela de tendência de 3 dias e cruzamento de Médias Móveis (rápida de 5 períodos e lenta de 20 períodos). O estado também incorpora a posição atual do portfólio (0 = Líquido, 1 = Comprado).
- **Espaço de Ações (A):** Discreto, composto por $A = \{0, 1, 2\}$, correspondendo a Manter, Comprar e Vender, respectivamente.
- **Dinâmica de Transição (T):** No Q-learning, o ambiente reage às ações avançando o tempo e flutuando os preços. Para o planejamento via Bellman, a dinâmica $T(s, a, s')$ foi estimada empiricamente através da execução de episódios simulados exploratórios.
- **Função de Recompensa (R):** O lucro ou prejuízo, calculado pela variação do valor total do portfólio (saldo em caixa + valor das ações retidas) após a transição.

O ambiente desenvolvido gera séries temporais sintéticas baseadas em uma função senoidal acrescida de ruído gaussiano, permitindo um treinamento controlado sob incerteza.

2 Equações de Bellman

A partir do mapeamento empírico do ambiente, aplicamos o algoritmo de Value Iteration para encontrar a política ótima. A atualização seguiu a Equação de Otimalidade de Bellman:

$$V(s) \leftarrow \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V(s')]$$

O critério de convergência adotado foi um limiar $\theta = 10^{-5}$, interrompendo a iteração quando a maior mudança Δ em $V(s)$ se tornou estritamente inferior a este valor.

2.1 Análise do Planejamento

A execução do algoritmo *Value Iteration* demonstra a eficácia do planejamento baseado nas Equações de Bellman aplicadas ao cenário financeiro. Durante o processo, as recompensas futuras esperadas são propagadas iterativamente para refinar a estimativa de valor $V(s)$ de todos os mapeamentos de estado.

Devido ao uso do fator de desconto $\gamma = 0.95$, essa atualização atua como uma contração matemática estrita. O script itera os cálculos de Bellman continuamente até que o erro máximo (Δ) convirja para o limiar de tolerância configurado de $\theta = 10^{-5}$.

O resultado prático dessa estabilização teórica é demonstrado nos gráficos gerados pelo modelo. Os gráficos de calor (como ilustrado na Figura 1) representam justamente o estado de equilíbrio final da função de valor após a convergência, revelando visualmente os estados que a inteligência artificial identificou como detentores de maior lucro esperado a longo prazo. É a partir da estabilidade desta matriz final que se torna possível extrair de forma determinística os mapas da Política Aprendida (Figura 2), ditando a ação ótima (Comprar, Vender ou Manter) para cada situação.

Por fim, os resultados dessa abordagem são demonstrados nos gráficos de desempenho financeiro (Figura 3), que quantificam o lucro absoluto obtido pela execução dessa política em cada mapeamento de estado.




Figure 1: Mapa de calor representando a estabilização dos valores dos estados $V(s)$ após a convergência do Value Iteration.




Figure 2: Política ótima determinística extraída a para cada mapeamento.




Figure 3: Comparação do desempenho financeiro absoluto alcançado pela política exata nos diferentes mapeamentos de estado.

3 Q-learning

Para o agente livre de modelo, implementamos o algoritmo Q-learning, que aprende a função de valor de ação seguindo a regra de atualização:

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

A inicialização da Tabela Q foi feita dinamicamente com valores zero à medida que novos estados eram descobertos. A exploração utilizou a estratégia ϵ -greedy com taxa de decaimento $\epsilon_{decay} = 0.995$ ao final de cada episódio, garantindo transição suave de exploração para exploração.

Utilizando a técnica de Grid Search, avaliamos o impacto da taxa de aprendizado (α) e do fator de desconto (γ).




Figure 4: Lucro Médio Final obtido para diferentes valores de α e γ .

Os resultados da busca confirmaram a expectativa para ambientes estocásticos como o mercado financeiro, demonstrando que as menores taxas de aprendizado (α) combinadas com altos fatores de desconto (γ) tendem a gerar os maiores lucros. Como os preços do ambiente foram modelados com a adição de ruído aleatório em uma curva senoidal, o mercado simulado apresenta alta volatilidade. Nesse contexto, um α baixo atua como um filtro estabilizador, impedindo que o agente altere bruscamente sua estratégia e a sua Tabela Q a cada flutuação momentânea. Simultaneamente, um γ elevado mostra-se crucial para o domínio financeiro, pois as decisões de investimento dependem da valorização do capital ao longo de múltiplos passos, forçando o agente a priorizar recompensas futuras consolidadas em vez de buscar ganhos imediatos e gananciosos.

Apesar dessa tendência geral, observou-se uma anomalia na linha de menor taxa de aprendizado ($\alpha = 0.01$), onde o lucro cai ao transitar de $\gamma = 0.5$ para 0.8 e 0.95, antes de atingir o pico em 0.99. Esse comportamento inesperado decorre das limitações do espaço de estados e da dinâmica de treinamento. Como a modelagem do estado retém poucas informações sobre o passado, forçar uma alta valorização do longo prazo induz o modelo a criar falsas correlações, tentando otimizar padrões futuros baseados em dados insuficientes. Além disso, a velocidade de convergência é severamente prejudicada pela configuração: como o treinamento foi executado por apenas 400 episódios, as atualizações minúsculas geradas por $\alpha = 0.01$ fazem com que a propagação de recompensas futuras com γ alto demore muito a alcançar os estados iniciais. Consequentemente, o agente não teve tempo hábil para convergir, tornando-se suscetível à alta variância da exploração e correndo o risco de ficar estagnado em ótimos locais menos eficientes.

4 Avaliação Experimental

4.1 Evolução do Aprendizado

A Figura 5 ilustra a recompensa acumulada por episódio em contraste com a evolução do parâmetro de exploração (ϵ).

Conforme a estratégia ϵ -greedy descrita anteriormente, observa-se que nos episódios iniciais — onde o ϵ está em seu valor máximo próximo a 1.0 — a curva de recompensa apresenta alta volatilidade e lucros frequentemente subótimos. Esse comportamento é esperado e reflete a fase de pura exploração, na qual o agente toma decisões de forma majoritariamente aleatória para descobrir as dinâmicas do ambiente financeiro e mapear a Tabela Q.

À medida que a taxa de decaimento atua e o ϵ decresce em direção a zero, o agente transita para a fase de *exploitation* (aproveitamento). Os gráficos evidenciam a superioridade do mapeamento Janela nessa abordagem: acompanhando a queda do ϵ , a curva de lucro se estabiliza em patamares altos e consistentes nas iterações finais, enquanto para os outros mapeamentos, essa curva permanece instável. Essa estabilização comprova que o agente abandonou as escolhas aleatórias e passou a agir baseando-se no conhecimento consolidado de sua Tabela Q, convergindo para uma política lucrativa de compra e venda.




Figure 5: Evolução da recompensa acumulada e do decaimento da taxa de exploração (ϵ) ao longo do treinamento do Q-learning.

4.2 Planejamento vs Aprendizado

Ao comparar os lucros do agente treinado via Q-learning com o agente ótimo derivado das equações de Bellman, constatamos que ambas as abordagens são capazes de extrair políticas altamente rentáveis, mas operam sob paradigmas fundamentais distintos, conforme ilustrado na Figura 6.

O algoritmo *Value Iteration* (Bellman) atua como um método de planejamento *model-based*. Ao resolver as equações de otimalidade de forma exaustiva e *offline*, ele garante a convergência para uma política matematicamente ótima, propagando os valores esperados por todo o modelo empírico de transições e recompensas. Como resultado, seu desempenho financeiro no episódio de teste tende a representar o teto máximo de lucro que pode ser extraído daquela modelagem de estados.

Em contrapartida, o *Q-learning* opera como um método de aprendizado *model-free*. Sem acesso prévio às probabilidades de transição do mercado financeiro, o agente constrói sua função de valor de ação iterativamente, dependendo exclusivamente da interação (tentativa e erro) e da sua estratégia de exploração.

A proximidade dos lucros obtidos por ambos os métodos (Figura 6) valida a robustez do Q-learning. O resultado prova que o agente de aprendizado por reforço foi capaz de aproximar com sucesso a política ótima calculada pelas equações de Bellman, alcançando um desempenho prático equiparável sem a necessidade de um modelo perfeito do ambiente.




Figure 6: Comparação do lucro total no episódio de teste entre o planejamento exato (Equações de Bellman) e o aprendizado empírico (Q-learning).

5 Visualizações

Para complementar a análise, incluímos visualizações obrigatórias que não foram incluídas anteriormente no relatório:




Figure 7: Políticas aprendidas pelo Q-learning.




Figure 8: Episódios de teste das políticas aprendidas pelo Q-learning.

6 Discussão e Conclusão

Dificuldades encontradas: A principal dificuldade foi lidar com a estocasticidade do mercado financeiro. Durante a etapa de otimização de hiperparâmetros (Grid Search), notou-se uma anomalia na qual a combinação de baixas taxas de aprendizado ($\alpha = 0.01$) com fatores de desconto entre $\gamma = 0.5$ e $\gamma = 0.95$ gerou queda no lucro obtido. Essa dificuldade decorreu da pouca informação contida nos estados, o que induziu o algoritmo a criar falsas correlações ao tentar otimizar recompensas de longo prazo baseadas em dados insuficientes. Além disso, a limitação a apenas 400 episódios de treinamento dificultou a propagação de atualizações minúsculas, decorrentes da baixa taxa de aprendizado, prejudicando a velocidade de convergência do agente.

Trade-offs observados: Observou-se um claro compromisso entre a complexidade da representação do espaço de estados e a capacidade de aprendizado do algoritmo. O modelo Simples (1 dia) sofreu com ambiguidade de informações, enquanto o modelo Janela (3 dias) forneceu o contexto adicional para diferenciar situações e responder mais adequadamente. O principal trade-off observado foi que representações com maior contexto facilitam a estabilização de uma política rentável, mas exigem um maior tempo de exploração empírica para que o agente visite e atualize adequadamente as transições de todos os estados possíveis na Tabela Q.

Impacto da exploração: A adoção da estratégia ϵ -greedy com taxa de decaimento de 0.995 mostrou-se imperativa para o mapeamento inicial do ambiente financeiro. Nos estágios iniciais, com o fator ϵ próximo de 1.0, o comportamento excessivamente exploratório do agente gerou alta volatilidade nas ações e lucros predominantemente subótimos. Contudo, essa fase garantiu a descoberta das dinâmicas de transição. Por fim, à medida que a exploração decaía em favor da exploração (exploitation), o agente conseguiu estabilizar sua curva de recompensas acumuladas em patamares consistentemente altos, principalmente no mapeamento por Janela.

Limitações do modelo: O agente possui limitações atreladas à simplificação do domínio do problema. Embora tenhamos utilizado tanto dados reais quanto sintéticos, o ambiente se baseia em informações rasas sobre o mercado financeiro, carecendo da complexidade inerente à estrutura de um mercado real e seus fatores externos. Do ponto de vista da modelagem, o espaço de ações discreto ($A = \{0, 1, 2\}$) impossibilita o emprego de estratégias de alocação de portfólio proporcionais ou controle de risco fracionado e força o agente a operar de forma binária em relação ao capital (totalmente líquido ou totalmente comprado). Além disso, se perde muita informação ao descrever as flutuações do mercado apenas como "subiu" e "desceu". As variações poderiam ser melhor representadas por intervalos de variação percentual.

Relação entre teoria e prática: A análise comparativa entre as abordagens implementadas validou diretamente os preceitos teóricos de Processos de Decisão de Markov. O algoritmo Value Iteration atuou como um método exato de planejamento (model-based), resolvendo empiricamente as Equações de Otimalidade de Bellman até o limite de tolerância para encontrar o teto teórico absoluto de lucro daquele ambiente. Na prática, o Q-learning operou como uma técnica livre de modelo, sem acesso às probabilidades das dinâmicas de transição.